

<SVD>

1. 특이값분해

1) 개요

- 고유값 분해와 같이 행렬을 대각화하는 방법
- 행렬이 정방행렬이든 아니든 관계없이 모든 $m \times n$ 행렬에 대해 적용 가능

2) 수식

$$A = U \Sigma V^T$$

U : $m \times m$ 직교행렬, AA^T 를 고유값분해해서 얻어진 직교행렬

- U 의 열벡터들을 left singular vector 라고 부름

* 직교행렬 : $U^T = U^T$, $UU^T = I$

V : $n \times n$ 직교행렬, $A^T A$ 를 고유값분해해서 얻어진 직교행렬

- U 의 열벡터들을 right singular vector 라고 부름

Σ : U 와 V 의 고유값들의 square root를 대각원소로하는 $m \times n$ 직사각행렬, 각 대각원소들을 A 의 특이값 (singular value)라고 부름

3) 성질

(1) U, V 는 직교행렬

- 대칭행렬의 성질

1. 무조건 고유값 분해가 가능
2. 직교행렬로 대각화 가능

-> AA^T 는 대칭행렬이기 때문에 항상 U 와 V 가 존재하고 직교행렬이 됨.

(2) 특이값은 모두 양수이다

- AA^T 와 $A^T A$ 의 고유값들은 1. 모두 0 이상

- $A^T A v = \lambda v$ 에 양변에 v^T 를 곱해보면, $v^T A^T A v = \lambda v^T v$ 에서 $(Av)^T Av = \lambda v^T v$

- 즉, $Av^2 = \lambda v^2$

- 0이 아닌 고유값들은 서로 동일.

- $(A^T A)v = \lambda v$ 이다. 양변에 A 를 곱해보면 $A(A^T A)v = \lambda Av$ 즉, $AA^T(Av) = \lambda(Av)$

- 즉, $Av \neq 0$ 이면 λ 는 또한 AA^T 의 고유값

- 만일 $Av=0$ 라 하면 $(A^T A)v = \lambda v$ 에서 $\lambda=0$ 이어야 한다. 그런데 $AA^T(Av) = \lambda(Av)$ 여기에서 Av 는 고유벡터이어야 하기 때문에 $Av \neq 0$ -> 성립하지 않음.

- 이와같이 구한 공통의 고유값들 $\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_s^2 \geq 0$ (단, $s = \min(m, n)$), 이들의 square root를 취한 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_s \geq 0$ 이 A 의 특이값(singular value) ≥ 0 (square root 중 양수값을 특이값으로 하기로

약속)

* positive define, negative define

-

(3) A가 정방행렬일때, 특이값에 0이 포함되면 A는 특이행렬(singular matrix).

$$- A^T A v = \lambda v \rightarrow (A^T A - \lambda I) v = 0 \rightarrow (A^T A) v = 0$$

-이때, 만약에 A의 역행렬이 존재하면 $v \neq 0$ 이라는 성질이 성립하지 않기 때문에 A는 역행렬이 존재하지 않음

$$(4) \quad A v_i = \sigma_i u_i, \quad 1 \leq i \leq s$$

u_i : left singular vector

σ_i : 특이값

v_i : right singular vector

-> 고유값 분해와 유사

4) 특이값분해(SVD)의 기하학적 의미

- 행렬은 선형변환

- 직교행렬 : 회전변환/반전된 회전변환

- 대각행렬 : 각 좌표성분으로의 스케일변환

이때, 행렬 R이 직교행렬(orthogonal matrix)이라면 $R R^T = E$ 이다. 따라서 $\det(R R^T) = \det(R) \det(R^T) = \det(R)^2 = 1$ 이므로 $\det(R)$ 는 항상 +1, 또는 -1이다. 만일 $\det(R)=1$ 라면 이 직교행렬은 회전변환을 나타내고 $\det(R)=-1$ 라면 뒤집혀진(reflected) 회전변환

5) SVD를 이용한 데이터 압축($A: m \times n, m > n$)

- full SVD

$$\boxed{A} = \boxed{U} \begin{array}{|c|} \hline \sigma_1 \vdots \sigma_s \\ \hline 0 \\ \hline \end{array} \boxed{V^T} \quad : \text{행렬을 단순히 분해하는 것}$$

- thin SVD

$$\boxed{A} = \boxed{U_s} \begin{array}{|c|} \hline \sigma_1 \vdots \sigma_s \\ \hline \end{array} \boxed{V^T} \quad : \text{비대각원소가 0으로 구성된 부분을 없애고, U에서 이에 대응되는 열벡터들을 제거한 형태.}$$

- Compact SVD

$$A = U_r \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} V_r^T$$

: 비대각원소들 뿐만 아니라 0인 대각원소들도 모두 제거한 형태

- Truncated SVD

$$A' = U_t \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_t \end{bmatrix} V_t^T$$

: 0이 아닌 대각원소들까지 제거한 형태, 다른 방법들과 달리 원래의 A가 보존되지 않고 근사행렬이 나옴. 데이터 압축을 위해서 많이 사용

참고자료 : <https://darkpgmr.tistory.com/106>