


## 베이지 가우시안 혼합 모델(Bayes Gaussian Mixture model)

- 사전 지식(ex 클러스터가 적을 것이라는 믿음 등)을 반영한 GMM모델
- 최적의 클러스터 개수를 수동으로 찾지 않고 불필요한 가중치를 0으로(또는 0에 가깝게) 만들
- 데이터의 수가 많아질수록 사전 지식은 중요하지 않음


### <기존 GMM 과의 차이>

- 기존 GMM
  - $\Sigma, \mu, \pi \rightarrow$  파라미터
  - $z$  : 클러스터 할당 변수



<GMM, 출처 : 핸드온 머신러닝2>

- Bayesian Gaussian Mixture model
  - $\Sigma, \mu, \pi \rightarrow$  잠재변수
  - $z$  : 클러스터 파라미터, 할당 변수, 파라미터에 의해 사전 믿음이 반영됨.
  - $\lambda$  : 파라미터



<Bayesian Gaussian Mixture model, 출처 : 핸드온 머신러닝2>

### <Variational Inference>

- w에 대한 prior(\* $\pi$ 는 베타분포에서 샘플링,  $\sigma$ 는 공분산 행렬에서 샘플링)가 있기 때문에 posterior을 구하겠다.

$$posterior = p(z|X) = \frac{p(X|z)p(z)}{evidence}, evidence = \int p(X|z)p(z)dz \rightarrow \text{evidence를 구하기 어려움}$$
$$\Rightarrow q(z|\lambda)$$

- 목적 :  $p(z|X)$ 와  $q(z|\lambda)$ 를 가장 비슷하게 하는  $\lambda$ 를 찾는 것이 목표

$$\begin{aligned} - D_{KL}(q(z|\lambda) \| p(z|X)) &= \sum_z q(z|\lambda) \ln \left( \frac{q(z|\lambda)}{p(z|X)} \right) \\ &= E_q \left( \ln \left( \frac{q(z|\lambda)}{p(z|X)} \right) \right) \\ &= E_q (\ln(q(z|\lambda))) - E_q (\ln p(z|X)) \\ &= E_q (\ln(q(z|\lambda))) - E_q (\ln p(z, X)) + E_q (\ln p(X)) \\ &= \ln p(X) - (E_q (\ln p(z, X)) - E_q (\ln q(z|\lambda))) \\ &= \ln p(X|\lambda) - ELBO, ELBO = E_q (\ln p(z, X)) - E_q (\ln q(z|\lambda)) \end{aligned}$$

\*ELBO는 evidence의 lower bound

$\Rightarrow \therefore$  ELBO를 최대화하는  $\lambda$ 를 찾음 (EM Algorithm / Gradient descent 사용)